ICS 35.240.99
L 67

中华人民共和国国家标准

GB/T 28513—2012

使用低比特率视频通信的手语和唇读实时会话应用配置

Application profile—Sign language and lip-reading real-time conversation using low bit-rate video communication

(ITU-T H. Suppl:1999,MOD)

2012-06-29 发布　　2012-10-01 实施

中华人民共和国国家质量监督检验检疫总局
中国国家标准化管理委员会　发布

目　　次

前言 …… Ⅰ
1　范围 …… 1
2　规范性引用文件 …… 1
3　术语和定义 …… 1
4　缩略语 …… 1
5　再现手语和唇读的基本需求 …… 2
5.1　基本特征 …… 2
5.2　时间分辨力要求 …… 2
5.3　空间分辨力要求 …… 6
5.4　保真度 …… 7
5.5　延时 …… 7
5.6　同步 …… 7
5.7　性能要求 …… 7
6　性能验证 …… 8
6.1　参考资料 …… 8
6.2　性能评估 …… 8
7　对终端实施者的建议 …… 9
8　对用户的建议 …… 9
9　扩展应用范围 …… 9
附录 A（资料性附录）　手语视频测试集技术描述 …… 10
A.1　技术描述 …… 10
A.2　手语内容 …… 10
A.3　一般的标记内容 …… 11

前　言

本标准按照 GB/T 1.1—2009 给出的规则起草。

本标准使用重新起草法修改采用 ITU-T　H.supp1《使用低比特率视频通信的手语和唇读实时会话应用配置》(1999 年英文版)。

本标准与 ITU-T　H.supp1(1999 年英文版)相比在结构上基本一致,内容上的主要不同点在于采用了中国手语和唇读视频序列和中国手语录制的视频测试内容,而 ITU-T　H.supp1(1999 年英文版)中的相应内容是英文手语和唇读。

本标准由中华人民共和国工业和信息化部提出。

本标准由中国通信标准化协会归口。

本标准起草单位:工业和信息化部电信研究院、黑龙江省牡丹江市特殊教育学校、广州残疾人学院、中国广播电视大学。

本标准主要起草人:聂秀英、陈曦、刘建梅、盛敏双、陈守刚、陈建。

使用低比特率视频通信的手语和唇读实时会话应用配置

1 范围

本标准规定使用具有或不具有可读语音的手语和唇读，用于人对人会话的视频通信系统所需要的特性。给出了确保成功的会话所需要的性能要求。描述了对手语和唇读性能评估的方法。

本标准建议除了相关的视频编码协议外还应考虑的因素。如终端设计以及用做手语和唇读的终端所使用的环境。包括评估手语的视频通信的视频测试序列。

本标准适用于使用具有或不具有可读语音的手语和唇读，用于人对人会话的视频通信系统的研发、生产、应用和验收测试。

2 规范性引用文件

下列文件对于本文件的应用是必不可少的。凡是注日期的引用文件，仅注日期的版本适用于本文件。凡是不注日期的引用文件，其最新版本(包括所有的修改单)使用于本文件。

ITU-T G.114 单向传输时间(One-way transmission time)

ITU-T P.931 多媒体通信延时、同步和帧速率测量(Multimedia communications delay, synchronization and frame rate measurement)

ITU-T T.140 文本会话协议(Protocol for multimedia application text conversation)

3 术语和定义

下列术语和定义适用于本文件。

3.1

帧 frame

视频再现中的一个完整的图像称为“帧”。在一些系统中，帧由两个半图像构成，每一个图像包含帧的信息中的一半。将这些半图像成为“场”。

4 缩略语

下列缩略语适用于本文件。

CIF	Common Interchange Format (352×288 pixels)	公共互换格式(352×288 像素)
fps	frames per second;pictures per second	每秒的帧数;每秒图像数
QCIF	Quarter CIF (176×144 pixels)	四分之一 CIF (176×144 像素)
SQCIF	Sub QCIF (112×96 pixels)	子 QCIF (112×96 像素)
VHS	Video Home Syetem	家用录像系统

5 再现手语和唇读的基本需求

5.1 基本特征

手语的构件是手、眼、嘴、脸和身体的运动和位置。

在唇读中，构件是脸的运动。通常情况下声音支持唇读。在其他情况下，是手语的组合。也有一些聋人不使用手语而仅仅依靠唇读交谈。

在视频编码领域中，具有一个(用手势的)示意者或讲话者的情景可以被认为是包含有中到多的运动内容。

5.2 时间分辨力要求

手语和唇读均需要好的运动视觉再现。若系统使用均匀分布的图片来再现运动，可以观察到如下一些情况：

- 当帧速为 20 fps 时，手语和唇读的可用性为好。
- 在有某些约束时，可以使用从 12 fps 到更高的帧速。
- 对于使用唇读进行会话，当帧速不超过 15 fps 时，随着帧速的增加，可用性急剧增加。当帧速高于 15 fps 时，随着帧速的增加，可用性继续增加，但不明显。
- 当帧速在 8 fps 和 12 fps 之间时，可用性受到很大限制，语义表达能力严重下降。
- 当帧速低于 8 fps 时，对于唇读和手语没有实际的可用性。

5.2.1 用指语字母交谈或交流

手语是一种字母表中的每一个字母对应一个特定手位置的技术。对于不同国家，手语位置是不同的。通过以快速次序显示这些位置以形成词语来实现。这些拼写的词通常是主要手语不包含的名称和其他特定的名词。手语在日常应用情况下速度一般为每秒最多使用 10 个字符。为可靠再现手语，每个字符至少应再现两个图形。因此，清晰地再现手语需要每秒至少显示 20 帧图像。

5.2.2 一般的手语

用指语字母交谈或交流仅是手语的一部分。手语的较大部分是通过标记来表示完整的概念、部分句子、语法和普通的名词。世界上有许多种手语。即使这些手语是不同的，本标准中相关描述将尽可能足够接近公共概念，使本标准对这些手语均有效。同样，在一般的手语期间，快速的手运动同时出现的短的眼睛闪动也携带语法信息。在许多情况下，时间分辨力需要类似于用指语字母交谈或交流需要的那些需求。

5.2.3 唇读

对于唇读的一般图形需求可以从一般语言的音素计算出来。一般速度是每秒 10 个音素。为使观看者观察到可见的音素，每秒应再现至少 20 帧图片。

5.2.4 适应

在唇读和手语的两种情况下，语言再现的速度可以根据意愿适当降低。这就解释了在一些特定情况下可以使用每秒 12 帧～15 帧的原因。有经验的唇读者和手语使用者也具有根据以往经验和相关冗余信息猜测出具体语义的能力。对于部分用户而言，可能会在连接上使用比上面所列出的质量要求低一些的短会话。

5.2.5 帧率要求分析

对测试序列“广播电视速度手语视频”需要进一步解释分析。

表 1 给出测试序列“广播电视速度手语视频”中的用手语交谈或交流序列的近似表示。图 1 中给出了该序列的图形。

表 1 每秒 25 帧和 12.5 帧下以帧表示的用手语交谈或交流举例

帧号	96				100					105					110					115				
25 fps	听	听	听	听	—	力	—	语言	语言	语言	—	—	—	康复	康复	康复	康复	康复	—	技术	技术	技术	技术	技术
12.5 fps	听		听		—		—		语言		—		—		康复		康复		—		技术		技术	
帧号	120					125					130					135					140			
25 fps	技术	技术	技术	—	—	—	—	学院	学院	学院	学院	学院	学院	学院	—	—	—	—	是	—	专	专	专	专
12.5 fps	技术		技术		—		—		学院		学院		学院		—		—		是		专		专	
帧号		145					150																	
25 fps	专	专	专	—	—	—	门	门	门	门														
12.5 fps	专		专		—		门		门															

表 1 中第一行的数字是序列开始的帧数。文字指示由手语表示的情况。破折号表示在文字之间转换时构成的不清楚的图片。例子中的字是一句话中摘录的一部分“听力语言康复技术学院是专门”。

在每秒 2.5 帧的情况下，这 9 个字或词语之中，有 2 个在一帧中清晰可见，因而可能有丢失的危险。这种情况在编码方案中每隔一帧跳过一帧时出现。在该表的较低一行中给出了 12.5 fps 抽样的情况。该行表明最初的“听力语言康复技术学院是专门”语句中仅保留了“听语言康复技术学院是专门”。这清楚地表明了在帧率低于 20 fps 时出现的语言内容丢失的情况。

在 25 fps 序列中，字或词语的分布情况如下：

在 1 帧中出现的字或词语个数　　2 个；

在 2 帧中出现的字或词语个数　　0 个；

在 3 帧中出现的字或词语个数　　1 个；

在 4 帧中出现的字或词语个数　　2 个；

在 5 帧中出现的字或词语个数　　1 个；

在 7 帧中出现的字或词语个数　　2 个；

在 8 帧中出现的字或词语个数　　1 个。

短语中的平均长度是：每个字或词语 4.4 帧。

小结

在该例子中，在时间上，语句中的字或词语在 1 到 8 帧之间变化，每一帧表示 40 ms。每一个字母可见的平均长度是 4.4 帧。该例子没有足够长来表示所有实际的统计结果。然而，这个例子可以表明，该用指语字母交谈或交流 25 fps 的帧率是足够的了，而 12.5 fps 的帧率需要一些猜测才能确定字或词语。

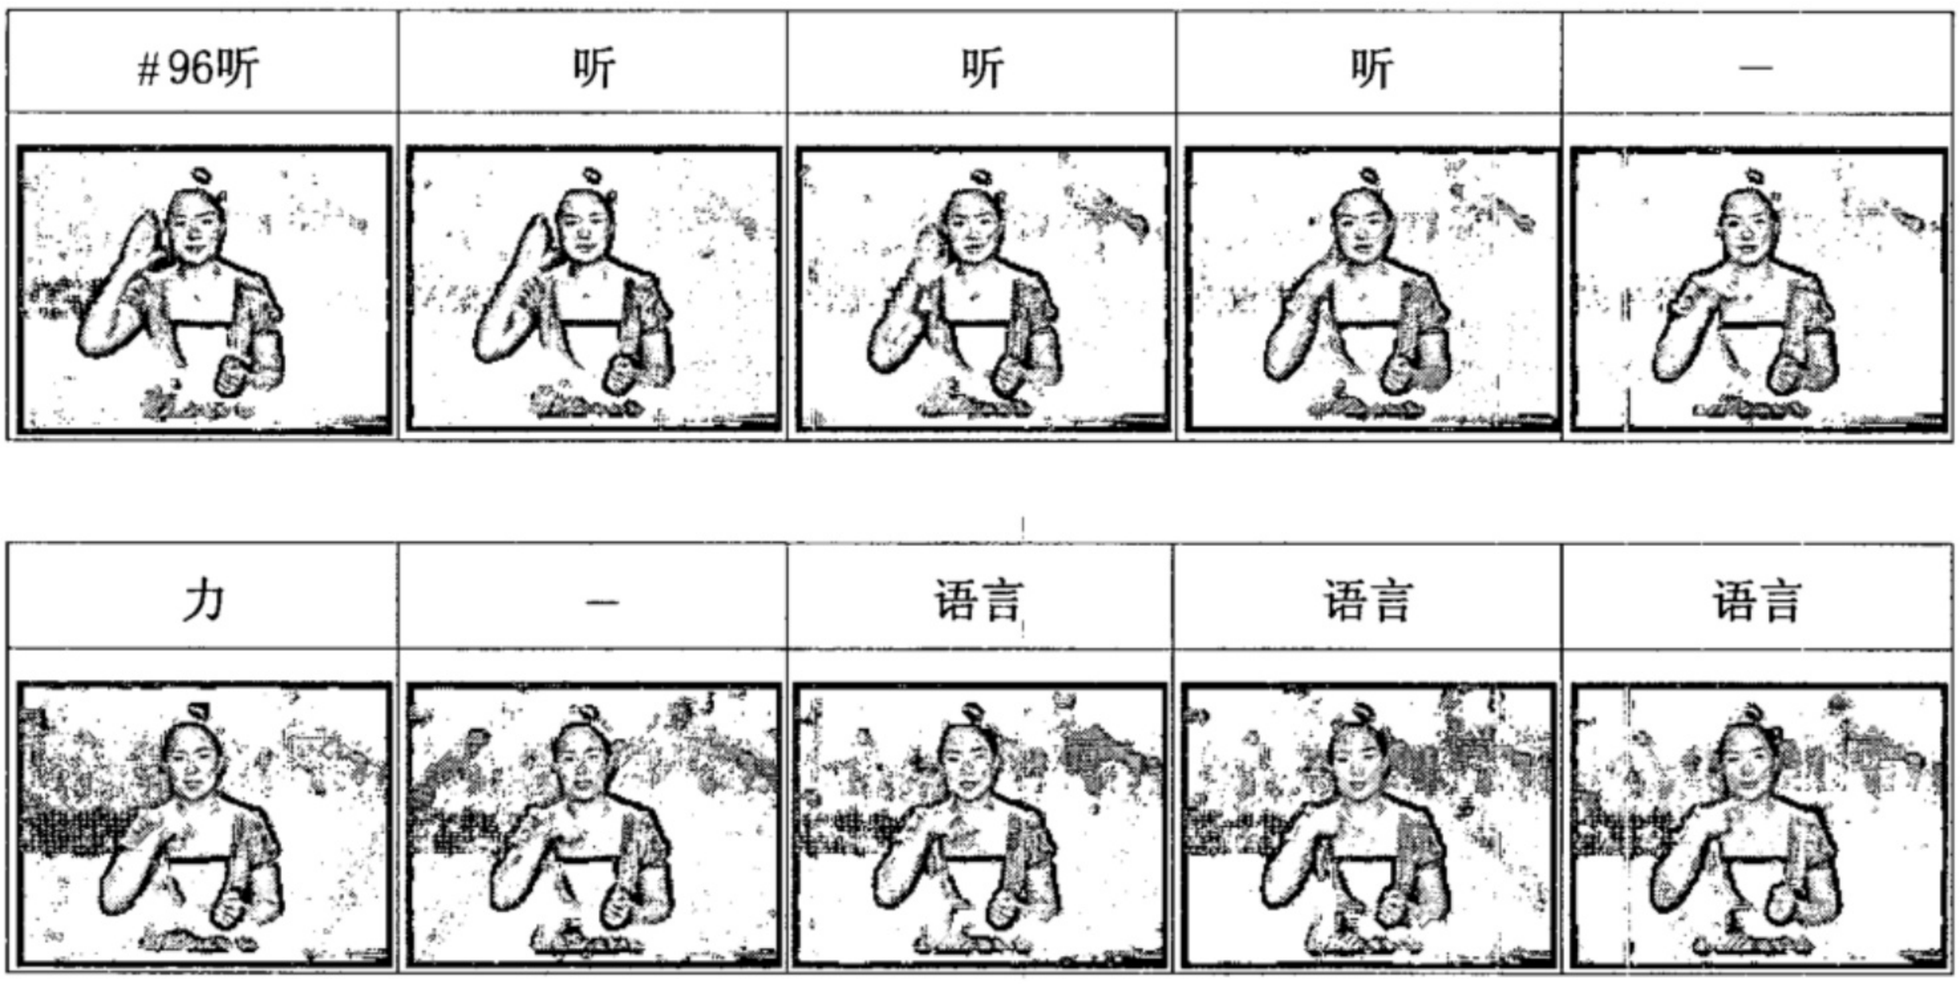


图 1　包含有用手语交谈或表示每秒 25 帧记录的词语“听力语言康复技术学院是专门”的各帧

技术	技术	技术	技术	技术
				

技术	技术	—	—	—
				

—	学院	学院	学院	学院
				

学院	学院	学院	—	—
				

—	是	是	—	#140专
				

专	专	专	专	专
				

图 1（续）

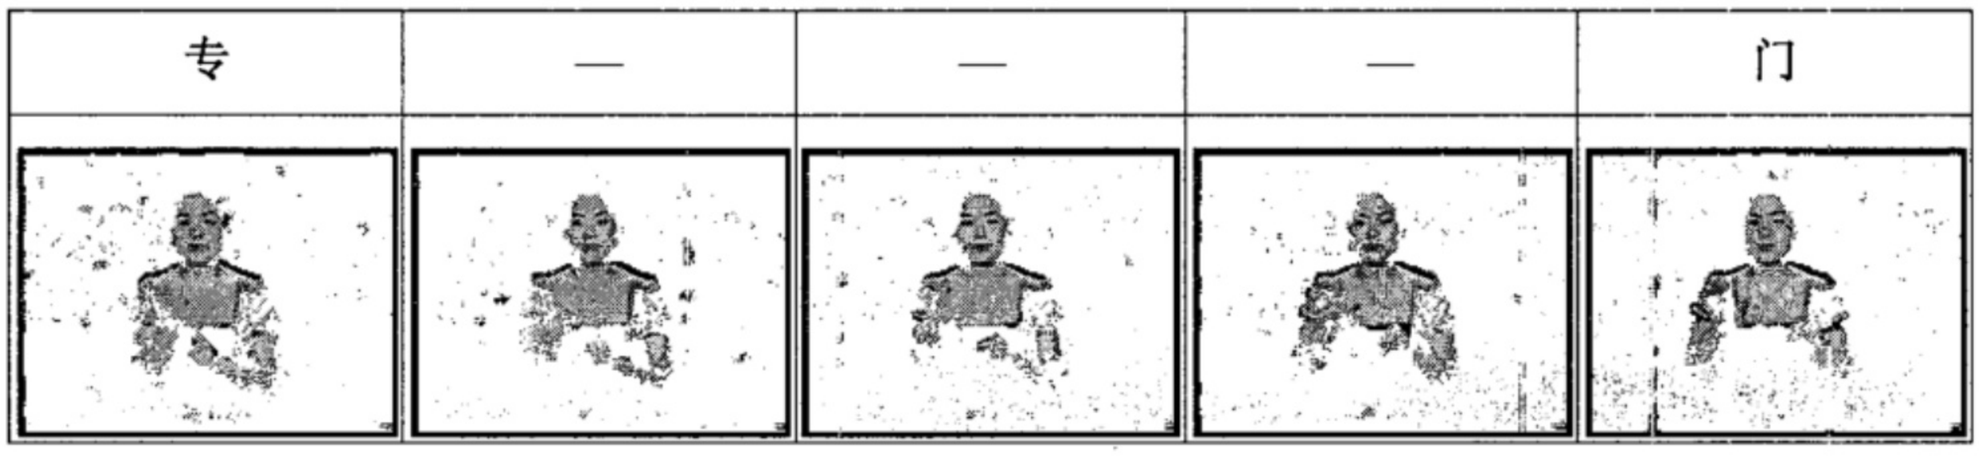


图 1（续）

一般标记

视频序列“广播电视速度手语视频”没有采用指语汉语拼音交谈或表示的符号来标记。

通过对其中一个短语进行简单的分析。可将“广播电视速度手语视频”序列的 354 和第 412 帧之间的帧序列短语描述为：“面向(5)全(3)国(5)招(6)收(5)高中(6)毕(6)业(7)生(4)”（在圆括号中逐符号地每一标记所占的帧数描述出来）。

在该序列中没有一个符号少于 2 帧，同时没有包含比用指语汉语拼音交谈或表示更快的运动。一些标记包含较大的运动因而对视频编码施加了不同的要求。

5.2.6 时间分辨力颗粒

在大多数情况下，视频摄像机用于遵循一般的视频标准的视频通信。这意味着，它们每秒钟输出 25 或 30 帧。该事实引入了一个有用的帧数速率颗粒度。在使用这类摄像机时，不需要考虑帧速是在 12.5 fps 和 25 fps 之间或是在 15 fps 和 30 fps 之间。这类中间帧速意味着源图片间隔将分别在 40 ms 和 80 ms 之间或在 33 ms 和 66 ms 之间变化，这样会引入丢失一些运动细节的危险。因此可得出结论为满足目标帧率每秒 20 帧的要求，一般摄像机应是每秒 25 帧或 30 帧。

5.3 空间分辨力要求

用于人对人手语通话的空间分辨力要求如下：

- 可以使用 QCIF 分辨力，但是将丢失显示眼睛凝视方向的最小细节。这将引起对观察者的额外压力。
- CIF 较好。从 QCIF 增加到 CIF 图像将传达出较完整的语义信息。
- 对于可靠的接收，SQCIF 太粗糙，此时一些标记可能偶尔会被感觉到。

若对于图片的不同部分使用不同的分辨力，手和脸将需要最高的分辨力。在这类配置下，需要注意不要在图片的其他部分引入失真，因为这些失真可能会误导观察者。

可以进行简单的理论验证。在从头到胃部的视觉范围内，通常在人到人手语通话中，手指近似于图片宽度的 1/50。为在图片中可靠地解析手指，应至少使用 3 个像素来表示手指。将最小空间分辨力要求规定为 QCIF，宽度上包含 176 个像素。在视觉语言上，眼睛凝视方向也很重要并需要较高的分辨力。因而，CIF 分辨力较好，建议作为优选选项。

对于唇读，在人际对话时，视觉范围可以缩小到稍微大于头部范围。在这种情况下，QCIF 对于唇读有足够的分辨力。当使用 QCIF 分辨力时，观察者必须确保在合适的距离观看显示器，这样相对低的分辨力将不会引起额外的语义误差。

5.4 保真度

在视频通信中，模糊通常出现在运动中。

目前描述模糊的模型并没有很好地建立起来。在模糊类型以及其对感觉的影响方面具有较大分歧。因而，本标准仅描述在不同场合下，可接受模糊的简单比较。

对手语和唇读，VHS 视频能够传达足够完整的语义。在视频记录中，由于人眼的关闭速率通常是从 1/50 s 到 1/60 s，快速运动客体通常显示出相当客观的模糊。这表明模糊在标记中包含有较大运动的快速运动客体是可以接受的。

在具有较明显的运动时，一些模糊可能会偶然被引入。在这类运动期间，空间分辨力不能低于与 SQCIF 相对应的空间分辨力。

对于较为完整的语义表达，当 CIF 是基本空间分辨力时，偶然引入的模糊不应超过对 QCIF 分辨力所期望的模糊程度。

5.5 延时

在会话应用中，从摄像机发送到接收显示的端到端音视频延时长度要求是非常严格的。建议低于 0.4 s 的值，优选低于 0.1 s。

超过 0.8 s 的值将会使人感到有碍标记会话。

对手语和唇读的要求与语音会话要求类似。从一个意愿到期望的反应被看见或听到至少是延时的两倍。ITU-T G.114 所规定的 0.4 s 的限制意味着将响应延时 0.8 s，该值(0.4 s)对于手语及唇读语义理解较长。

5.6 同步

对于唇读支持的语音，声音和视频的同步要求是必须的。可接受的时间差不应超过 100 ms。对于可以同时使用语音和唇读的人来说，这两者的组合对语义理解来说是非常有效的。

5.7 性能要求

对人际对话的手语和唇读传输的应用，要满足如下一些基本要求：

- 目标要求：在 CIF 分辨力下每秒 25 帧到 30 帧，最大延时 0.4 s，偶然的模糊不超过在中等运动情况下 QCIF 对应的模糊情况。
- 可接受的：若需要在非常低数据速率环境下工作，具有中等运动情况下应为 12 fps 到 15 fps，QCIF 分辨力，在大的手语运动期间偶尔可降低到对应于 SQCIF 的分辨力。
- 保持低于 100 ms 同步误差的同步情况。
- 端到端的延时应低于 0.4 s。若不可避免，最高不可超过 0.8 s。

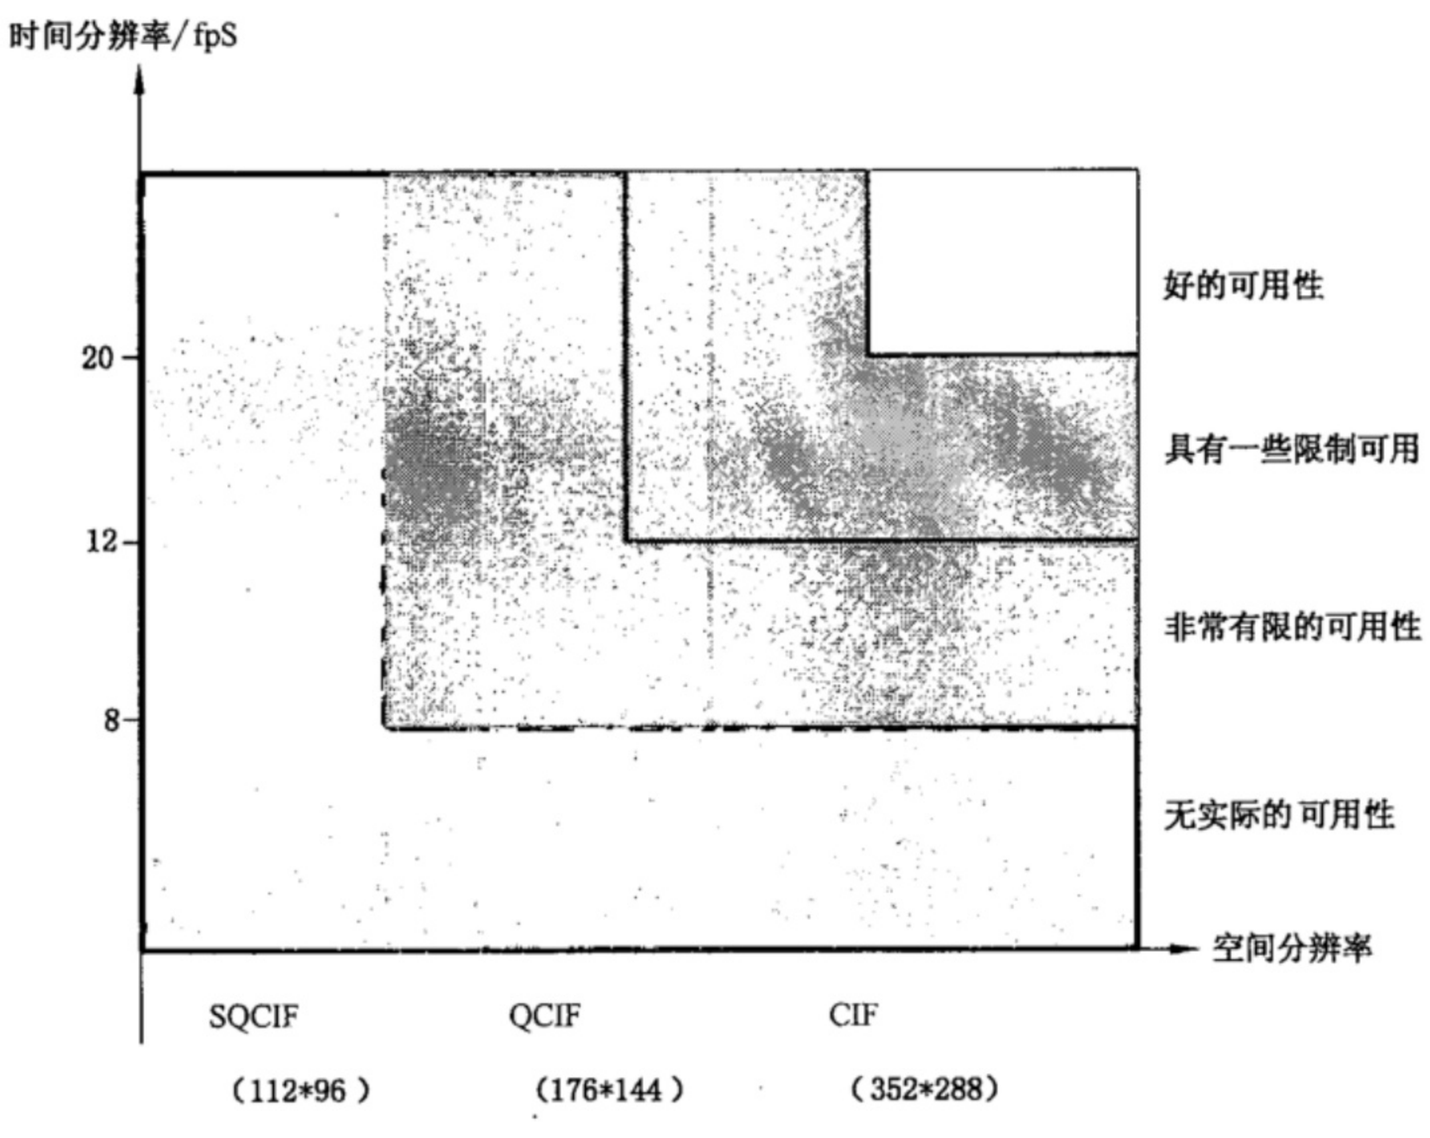


图 2　对人际对话中手语和唇读的分辨力要求

表 2　由延时和模糊引起的可用性降低情况小结

可用性	端到端延时	在大运动期间偶然模糊	
		对于 CIF 分辨力	对于 QCIF 分辨力
好	<0.4 s	无	—
具有一些限制可用	0.4 s～0.8 s	下降到≅QCIF	无
有限可用性	0.8 s～1.2 s	下降到≅SQCIF	下降到≅SQCIF
无实际的可用性	>1.2 s	下降到<SQCIF	下降到<SQCIF

6　性能验证

6.1　参考资料

本标准包括两个包含可以用于性能评估的手语视频的 DVD-ROM。视频文件“广播电视速度手语视频”和“教学速度手语视频”分别给出了采用中国手语录制的包括电视广播手语节目速度和教学用手语速度的测试视频序列。

附录 A 复制了 DVD-ROM Readme 文件，该文件包含了电子文件的说明和技术描述。

6.2　性能评估

在一个网络连接上通过利用编解码器或通过可视电话机传输评估情景来测试编解码器或终端情况。记录结果并评估。评估方法见 ITU-T P.931。

评估标记期间的帧率。

标注选择的静态分辨力。

通过将录制的具有图片的帧与分辨力下降到 QCIF 和 SQCIF 分辨力的相同场景相比较来测量在中等运动期间引入的额外模糊。仅对手和头部的图像模糊情况进行评估。

测量延时。

测量音频(语音)和视频(唇运动)的同步。

根据这些记录,可以评估性能并与上面描述的目标相比较。

7 对终端实施者的建议

为满足用户要求,在终端中应实现一些特定功能。

- 终端应提供与激活的外部告警系统的接口,例如,闪光灯、便携式震动器、手表大小的震荡器或强音发生器。
- 用户可能有时需要恢复到文本会话。因而建议在终端中实现文本会话协议(ITU-T T.140)。
- 优选使用帧频大于 20 fps、延时小于 0.4 s、以及没有帧跳变跃的编码算法。高帧率自动提供实现合理延时的机会。
- 在场景变换后,可以接受最大 2 s 的全质量要求偏差。

8 对用户的建议

用户应安排使用具有好的灯光条件以及一般背景的环境。

9 扩展应用范围

若设备在视频会议、组播、广播或信息检索中应用于手语或唇读应用,下列因素改变需求。

- 观看的范围通常较宽,包括打手语的人以及其他客体。表明可用性应在 CIF 空间分辨力以上。
- 对于用户而言,通过影响讲话者或打手语的人为控制感觉而给出反馈的可能性很小。
- 延时要求较为宽松。对于广播和信息检索,可以接受几秒钟的延时。对于会议,延时要求类似于会话应用的相关要求。
- 对于每一类应用的额外要求超出本标准的范围。

附 录 A
（资料性附录）
手语视频测试集技术描述

A.1 技术描述

本附录包含“广播电视速度手语视频”和“教学速度手语视频”两段视频序列的基本技术描述。

两段视频序列手语希望用于视频编码的测试集。包含广播电视速度和教学用速度的手语内容。

根据文字内容将视频命名为“广播电视速度手语视频”和“教学速度手语视频”。它给出了通常用于个人进行手语交流视频而使用的相同的半身像。按 25 fps 以 PAL 制式进行录制。并以 MPEG-2 格式提供：

教学速度手语视频. mpg (123648 Kbytes)

PAL 标准分辨力，25 fps，MPEG-2 编码；

广播电视速度手语视频. mpg (58163.2 Kbytes)

PAL 标准分辨力，25 fps，MPEG-2 编码。

A.2 手语内容

下面是在“教学速度手语视频”中的两个手语序列的近似表示。数目为从 MPEG-2 版本的开始的帧的数目。词语表示由手形成相当清晰的词语的时刻。破折号表示在字母之间转换的不清晰的字母。

"liu"

帧编号	字母	帧编号	字母	帧编号	字母	帧编号	字母	帧编号	字母
6144	l	6153	-	6162	i	6171	u	6180	u
6145	l	6154	i	6163	-	6172	u	6181	u
6146	l	6155	i	6164	-	6173	u	6182	u
6147	-	6156	i	6165	-	6174	u	6183	u
6148	-	6157	i	6166	-	6175	u	6184	u
6149	-	6158	i	6167	-	6176	u	6185	u
6150	-	6159	i	6168	-	6177	u	6186	u
6151	-	6160	i	6169	-	6178	u	6187	u
6152	-	6161	i	6170	u	6179	u	6188	u

l (3)-(7)i(9)-(7)u(19)

"huan"

帧编号	字母	帧编号	字母	帧编号	字母	帧编号	字母	帧编号	字母
6750	h	6760	-	6770	a	6780	-	6790	n
6751	h	6761	u	6771	a	6781	-	6791	n
6752	h	6762	-	6772	-	6782	n	6792	n
6753	h	6763	-	6773	-	6783	n	6793	n
6754	h	6764	-	6774	-	6784	n	6794	n
6755	-	6765	-	6775	-	6785	n		
6756	-	6766	-	6776	-	6786	n		

帧编号	字母	帧编号	字母	帧编号	字母	帧编号	字母	帧编号	字母
6757	-	6767	a	6777	-	6787	n		
6758	-	6768	a	6778	-	6788	n		
6759	-	6769	a	6779	-	6789	n		

h(5)-(6)u(1)-(5)a(5)-(10)n(10)

下面是在“广播电视速度手语视频”中的两个手语序列的近似表示。数目为从 MPEG-2 版本的开始的帧的数目。词语表示由手形成相当清晰的词语的时刻。破折号表示在字母之间转换的不清晰的字母。

"聋儿康复医学基础理论课程"

帧编号	词语	帧编号	词语	帧编号	词语	帧编号	词语	帧编号	词语
505	聋	517	-	529	-	541	-	553	课
506	聋	518	康复	530	-	542	-	554	课
507	-	519	康复	531	学	543	-	555	-
508	-	520	康复	532	学	544	k	556	-
509	-	521	康复	533	学	545	理论	557	-
510	-	522	-	534	-	546	理论	558	-
511	-	523	-	535	-	547	-	559	程
512	儿	524	-	536	-	548	-	560	程
513	儿	525	-	537	-	549	-		
514	儿	526	-	538	基础	550	课		
515	-	527	医	539	基础	551	课		
516	-	528	医	540	基础	552	课		

"听力语言康复技术学院是专门"

帧编号	词语	帧编号	词语	帧编号	词语	帧编号	词语	帧编号	词语
96	听	108	-	120	技术	132	学院	144	专
97	听	109	康复	121	技术	133	学院	145	专
98	听	110	康复	122	技术	134	-	146	专
99	听	111	康复	123	-	135	-	147	-
100	-	112	康复	124	-	136	-	148	-
101	力	113	康复	125	-	137	-	149	-
102	-	114	-	126	-	138	是	150	门
103	语言	115	技术	127	学院	139	-	151	门
104	语言	116	技术	128	学院	140	专	152	门
105	语言	117	技术	129	学院	141	专	153	门
106	-	118	技术	130	学院	142	专		
107	-	119	技术	131	学院	143	专		

A.3 一般的标记内容

相对于汉语拼音字母，在“广播电视速度手语视频”视频文件中完全用标记(没有指语字母交谈或表示)来表示。对其中表示的短语，逐标记可描述为“面向(5)全(3)国(5)招(6)收(5)高中(6)毕(6)业(7)生(4)”(在圆括号中表示每一个标记所占的帧数)。在 MPEG-2 版本中在第 354 和第 412 帧之间找到该序列。

中 华 人 民 共 和 国
国 家 标 准
使用低比特率视频通信的手语和唇读
实时会话应用配置
GB/T 28513—2012
*
中国标准出版社出版发行
北京市朝阳区和平里西街甲2号(100013)
北京市西城区三里河北街16号(100045)
网址 www.spc.net.cn
总编室:(010)64275323 发行中心:(010)51780235
读者服务部:(010)68523946
中国标准出版社秦皇岛印刷厂印刷
各地新华书店经销
*
开本 880×1230 1/16 印张 1 字数 23 千字
2012年10月第一版 2012年10月第一次印刷
*
书号:155066·1-45679 定价 18.00 元

如有印装差错 由本社发行中心调换
版权专有 侵权必究
举报电话:(010)68510107

GB/T 28513-2012

打印日期:2012年11月22日 F009A